

Przykład analizy psychometrycznej konstruktów ciemnej triady

Paweł Smoliński Uniwersytet Merito

1 Wprowadzenie

Poniżej omówię analizę psychometryczną konstruktu zwanego ciemną triadą. Ciemna triada to trzy negatywne cechy charakteru, które obejmują makiawelizm (czyli skłonność do manipulacji i oszustwa wobec innych), narcyzm (nadmierna fascynacja sobą, brak empatii) oraz psychopatię (brak empatii, impulsywność). Dla celów tej analizy skoncentruję się tylko na dwóch z nich: makiawelizmie i narcyzmie. Makiawelizm i narcyzm są powiązane teoretycznie, ponieważ obie te cechy dotyczą skupienia na własnym interesie, choć w nieco inny sposób. Według wielu badań te dwa konstrukty często korelują ze sobą, co oznacza, że osoby wykazujące wysoki poziom makiawelizmu często również wykazują wysoki poziom narcyzmu.

Dane, które będę analizować, pochodzą ze strony Open Source Psychometrics Project - miejsca, w którym można znaleźć mnóstwo interesujących zbiorów danych psychologicznych zgromadzonych od tysięcy ludzi. Jednakże dla celów naszej analizy zdecydowałem się uprościć te dane. Zamiast analizować cały, bardzo obszerny zbiór, skoncentrowałem się tylko na pierwszych 50 odpowiedziach z dziesiątek tysięcy dostępnych. Dlaczego? Chcę, aby dane, które omawiamy, były podobne do tych, które sami możecie zbierać podczas realizacji swojego projektu zaliczeniowego czy w przyszłości, podczas pisania pracy magisterskiej.

2 Organizacja danych

2.1 Wczytanie pakietów

Pierwszym krokiem w naszej analizie jest uruchomienie wszystkich pakietów statystycznych w języku programowania R. Pakiety statystyczne w R to zestawy narzędzi i funkcji stworzonych przez społeczność, które dodają nowe możliwości i funkcje do głównego języka programowania R. Można je porównać do aplikacji dodających nowe funkcje do Twojego smartfona. Poniżej znajdziesz długą listę pakietów, które musisz wczytać.

```
# Pakiet zapewniający zestaw narzędzi do przetwarzania i  
# manipulacji zbiorami danych w R.
```

```
library('dplyr')

# Pakiet do wizualizacji macierzy korelacji za pomoca
# roznorodnych wykresow.
library('corrplot')

# Pakiet do wizualizacji roznego rodzaju wykresow
library('ggplot2')

# Pakiet do psychometrii, zawierajacy narzedzia do
# przeprowadzania analizy rzetelnosci.
library('psych')

# Pakiet do eksploracyjnej analizy czynnikowej, sluzzy do
# uzyskiwania lepszej interpretacji czynnikow.
library('GPArotation')

# Pakiet do konfirmacyjnej analizy czynnikowej (CFA).
library('lavaan')

# Pakiety do wizualizacji modeli CFA za pomoca diagramow
# scieżkowych.
library('semTools')
library('semPlot')
```

2.2 Wczytanie i przejrzanie danych

Kolejnym krokiem w analizie jest wczytanie zbioru danych do R. Aby to zrobić, użyjemy funkcji `read.csv()`. Ta funkcja pozwala na wczytanie pliku CSV (Comma-Separated Values), co jest standardowym formatem przechowywania danych w tabelarycznej postaci.

```
dane <- read.csv('https://raw.githubusercontent.com/
PawelSmolinski/Psychometria/main/Dane/Ciemna%20triada/
dane50.csv')
```

W powyższym kodzie wczytujemy dane z podanego adresu URL i przypisujemy je do zmiennej o nazwie **dane**. Następnie, jeśli chcemy szybko zorientować się w strukturze naszego zbioru danych, używamy funkcji `str()`: Funkcja `str()` wyświetli krótki opis struktury naszego zbioru danych, pokazując typy kolumn, ilość obserwacji oraz pierwsze wartości w każdej kolumnie. Jest to bardzo użyteczne narzędzie, kiedy chcemy szybko zrozumieć, jakie informacje zawiera nasz zbiór danych. Jeżeli chcemy bardziej szczegółowo przyjrzeć się danym, możemy użyć funkcji `View()`:

```
str(dane)

View(dane)
```

Funkcja `View()` otworzy interaktywny widok naszych danych w oddzielnym oknie. Dzięki temu możemy przeglądać wszystkie kolumny i wiersze w czytelnej tabelarycznej formie (tak jak w Excelu!), co jest szczególnie pomocne przy większych zbiorach danych.

2.3 Zmiana nazwy i typu zmiennej

Po dokładnym przejrzeniu struktury naszych danych za pomocą funkcji `str()`, zauważyliśmy pewne nieścisłości w odniesieniu do jednej ze zmiennych. Mianowicie, zmienna **country** reprezentuje przynależność do kraju, co sugeruje, że jest zmienną kategorialną. Jednakże w naszych danych jest ona zakodowana jako "character" (w skrócie "chr"), co nie jest prawidłowym formatem dla takiego typu zmiennej. W swoich danych często będziecie spotykali tego typu zmienne, dlatego ważne jest umiejętność zmiany na właściwy typ. Chcemy przekształcić zmienną `country` w zmienną kategorialną, znaną w R jako "factor". W tym celu skorzystamy z funkcji `as.factor()`:

```
dane <- rename(dane, kraj = country)

dane$kraj <- as.factor(dane$kraj)
```

Jednak przed przekształceniem tej zmiennej, postanawiamy również zmienić jej nazwę na język polski dla naszej wygody i jednocześnie chcemy zademonstrować, jak łatwo jest zmienić nazwy kolumn w R. Do tego celu używamy funkcji `rename()` z pakietu `dplyr`.

3 Eksploracyjna analiza danych

Jak już wczytaliśmy i wstępnie zrozumieliśmy strukturę naszych danych musimy przeprowadzić eksploracyjną analizę danych. Eksploracyjna analiza danych (EDA) jest kluczowym krokiem w procesie analizy danych. Pozwala nam zrozumieć strukturę, właściwości i jakość naszych danych przed przystąpieniem do bardziej zaawansowanych analiz.

3.1 Macierz korelacji

Macierz korelacji przedstawia relacje pomiędzy wszystkimi itemami w naszym teście. Gdy mówimy o korelacji pozycji w teście, chodzi nam o to, jak konkretna pozycja (pytanie czy stwierdzenie) w teście jest związana z innymi pozycjami.

Z perspektywy psychometryka, wysoka korelacja między itemami może wskazywać, że oba mierzą tę samą cechę lub konstrukt, podczas gdy niska korelacja może sugerować, że itemy źle mierzą konstrukt.

Jednak, interpretacja macierzy korelacji jest wyzwaniem. W rzeczywistości, patrzenie na zestawienie pełne liczbowych wartości, takich jak te wygenerowane przez funkcję **print** może być przytłaczające i trudne do zrozumienia. Dlatego warto skorzystać z narzędzi wizualizacyjnych, takich jak **corrplot**. Funkcja ta tworzy mapę cieplną korelacji, gdzie kolory i ich intensywność odzwierciedlają zarówno kierunek (pozytywny lub negatywny), jak i siłę korelacji. Na przykład, intensywne niebieskie kolory wskazują na silne korelacje dodatnie, podczas gdy głębokie czerwone kolory oznaczają silne korelacje ujemne. Dzięki temu, analizujący dane mogą łatwiej dostrzec wzory i relacje między zmiennymi, nawet bez konieczności analizowania konkretnych wartości liczbowych.

```
macierz <- cor(dane[,1:18])
print(macierz)

corrplot(macierz, method = 'square')
```

Z tej wizualizacji macierzy korelacji dostrzegamy, że pewne zmienne (N2, N6 i N8) mają ujemne korelacje z resztą itemów, co sugeruje, że mogą być odwrócone w kontekście ich kodowania w stosunku do innych pozycji w teście. To potwierdza się, gdy przyjrzymy się pytaniom z testu na stronie Open Source Psychometrics. Na przykład item N6 brzmi: "I **hate** being the center of attention.", co jest odwróceniem cechy narcystycznej.

3.2 Statystyki opisowe

Zanim przystąpimy do odwracania pozycji testowych, warto pochylić się nad statystykami opisowymi, które dostarczają nam cennych informacji o naszych danych. Statystyki opisowe to zestaw wskaźników, które opisują główne cechy zbioru danych w skondensowanej formie. W kontekście psychometrii, gdzie zajmujemy się analizą odpowiedzi na poszczególne itemy testu, te wskaźniki mogą być bardzo ważne do oceny jakości naszych pomiarów. Do obliczania statystyk opisowych wykorzystujemy funkcję **describe()** z pakietu **psych**:

```
describe(dane[,1:18])
```

W wyniku tej funkcji zobaczymy statystyki takie jak: średnia, mediana, odchylenie standardowe, skośność i kurtosis dla każdego itemu. Zauważymy również, że itemy M3 i N6 zawierają wartość 0, co zgodnie z instrukcją testu oznacza brak odpowiedzi. W R, używamy wartości **NA** (Not Available) do reprezentowania brakujących danych. Zmienienie 0 na NA jest ważne, aby nie wprowadzać błędów w późniejszych analizach. Dokonujemy tego w następujący sposób:

```
dane$M3[dane$M3 == 0] <- NA
dane$N6[dane$N6 == 0] <- NA
```

3.3 Odwracanie itemów

Gdy już zidentyfikowaliśmy brakujące odpowiedzi i oznaczyliśmy je jako NA, możemy przystąpić do odwracania itemów. Jeśli badanie używa skali Likerta, odwracanie itemów jest stosunkowo proste. Skala Likerta jest zakresem wartości używanym do mierzenia postaw lub opinii respondentów. Na przykład, jeśli skala Likerta ma zakres od 1 do 5, odwrócenie wartości polega na przekształceniu 1 na 5, 2 na 4 itd. Jeżeli nasza skala jest 5 stopniowa, możemy zastosować prosty trick:

```
dane$N2 <- 6 - dane$N2
```

Jeśli chcemy odwrócić więcej niż jedną kolumnę jednocześnie, możemy użyć funkcji **mutate()** w połączeniu z funkcją **recode()**:

```
dane <- dane %>%
  mutate(across(c(N6,N8), ~recode(., '1' = 5, '2' = 4, '3' =
    3, '4' = 2, '5' = 1)))
```

Metoda, o której mówimy, jest bardziej skomplikowana, ale pozwala odwracać wiele zmiennych naraz. W funkcji **mutate** używamy funkcji **across**, w której wybieram wektor itemów (jak N6 i N8 w naszym przykładzie - **c(N6,N8)**) do odwrócenia.

3.4 Obliczenie i wizualizacja wyników testu

Istnieje wiele sposobów obliczania wyniku testu. Najpopularniejszą i najbardziej intuicyjną metodą jest obliczanie średniej wartości odpowiedzi na itemy składające się na dany konstrukt:

```
dane$makiawelizm <- rowMeans(dane[,1:9], na.rm = TRUE)
dane$narcyzm <- rowMeans(dane[,10:18], na.rm = TRUE)
```

Używamy funkcji **rowMeans()**, która oblicza średnią wartość dla wierszy w określonych kolumnach. Argument **na.rm = TRUE** sprawia, że funkcja pomija wartości NA przy obliczaniach, dzięki czemu otrzymamy precyzyjne wyniki dla każdej osoby badanej.

Po obliczeniu wyników testu dla każdej osoby, warto przyjrzeć się, jak te wyniki są rozłożone w naszej próbie. W psychologii jednym z podstawowych narzędzi do tego jest przedstawienie wyników w formie rozkładu. Rozkład to sposób przedstawienia, jak często występują różne wyniki w naszym zestawie

danych. Zrozumienie rozkładu jest kluczowe, nie tylko do zrozumienia charakterystyki naszej próby, ale także do sprawdzenia, czy dane spełniają pewne założenia statystyczne. W psychologii często zakładamy, że nasze dane mają rozkład normalny, co oznacza, że większość wyników skupia się wokół średniej, a mniej wyników znajduje się w skrajnych wartościach (czyli po obu stronach dzwonu).

Jednym ze sposobów wizualizacji rozkładu wyników jest histogram. Histogram to wykres słupkowy pokazujący, jak wiele osób uzyskało dany wynik w teście. Każdy słupek reprezentuje zakres wyników, a wysokość słupka pokazuje, ile osób uzyskało wynik w tym zakresie. Wykorzystując pakiet **ggplot**, możemy łatwo stworzyć histogram dla naszych danych. Oto jak to działa na podstawie podanej funkcji:

```
ggplot(dane, aes(x = makiawelizm)) +  
  geom_histogram(fill = "orange",  
                 color = "black", bins = 15) +  
  labs(title = "Rozklad_wynikow") +  
  theme_minimal()
```

Ostateczny wynik to przejrzysty histogram, który pokazuje rozkład wyników dla Makiawelizmu w naszej próbie. Choć funkcja do tworzenia histogramu w ggplot może wydawać się skomplikowana na pierwszy rzut oka, nie martwcie się! Jeśli kiedykolwiek napotkacie na trudności związane z interpretacją lub tworzeniem takich funkcji, zawsze możecie poprosić ChatBota (np.: Google Bard), o wyjaśnienie poszczególnych elementów funkcji lub nawet o napisanie funkcji za Was.

4 Analiza rzetelności

Rzetelność testu odnosi się do stopnia, w którym test jest spójny i daje powtarzalne wyniki, natomiast na poziomie teoretycznym jest to korelacja wyniku w teście z wynikiem prawdziwym. W kontekście testów rzetelność pozwala ocenić, czy test faktycznie mierzy to, co ma mierzyć.

Po przetworzeniu naszych danych (odwróceniu itemów i usunięciu brakujących odpowiedzi) wracamy do analizy macierzy korelacji. Tym razem jednak dodajemy argument **use = 'pairwise.complete.obs'**. Oznacza to, że obliczenia korelacji dla każdej pary zmiennych będą opierać się tylko na obserwacjach, które nie mają brakujących danych (jak pamiętamy nasz zbiór danych zaiwerał brakujące informacje).

```
macierz <- cor(dane[,1:18], use = 'pairwise.complete.obs')  
print(macierz)  
  
corrplot(macierz, method = 'square')
```

Zaktualizowana macierz korelacji ukazuje nam korelację pomiędzy wszystkimi itemami. Widzimy silną korelację między itemami w obrębie tych samych kon-

struktów (makiawelizm i narcyzm), co wskazuje na ich rzetelność. Niemniej jednak obserwujemy też pewne pokrywanie się korelacji między dwoma konstrukcjami.

Aby dokładniej ocenić rzetelność naszego testu, korzystamy z współczynnika Alfa Cronbacha, który obliczamy za pomocą funkcji `alpha()`. Jest to popularny wskaźnik rzetelności, który opiera się na średniej korelacji między itemami testu. Używając funkcji `summary(alfa)`, otrzymujemy podstawowe statystyki dla naszej rzetelności, w tym wartość współczynnika Alfa. Za pomocą `print(alfa$alfa.drop)` możemy ocenić, jak rzetelność by się zmieniła, gdybyśmy usunęli któryś z itemów pojedynczo. Dzięki temu możemy zidentyfikować potencjalnie istotne itemy, których usunięcie może obniżać ogólną rzetelność testu.

```
alfa <- alpha(dane[,1:18])
summary(alfa)
print(alfa$alfa.drop)
```

Musimy jednak zauważyć, że makiawelizm i narcyzm są osobnymi konstrukcjami w obrębie ciemnej triady, co oznacza, że mają swoje unikalne właściwości i charakterystyki. Dlatego kluczowe jest, by ocenić rzetelność każdego z tych konstrukcji oddzielnie. Wykorzystując funkcję `alpha()`, obliczamy rzetelność dla skal makiawelizmu i narcyzmu. Wyniki z `summary(alfa$makiawelizm)` i `summary(alfa$narcyzm)` prezentują nam współczynniki Alfa Cronbacha dla obu tych skal.

```
alfa_makiawelizm <- alpha(dane[,1:9])
summary(alfa_makiawelizm)

alfa_narcyzm <- alpha(dane[,10:18])
summary(alfa_narcyzm)
```

Interesującym zjawiskiem, które możemy zaobserwować, jest fakt, że rzetelność dla obu konstrukcji razem (kiedy traktujemy je jako jeden test) jest wyższa niż rzetelność każdego z tych konstrukcji osobno. To zjawisko jest związane z tym, że choć makiawelizm i narcyzm są teoretycznie różne, jak widzieliśmy w macierzy korelacji, ich itemy mają znaczące korelacje między sobą. Innymi słowy, itemy z jednego konstruktów w pewnym stopniu przewidują wyniki itemów z drugiego konstruktów.

Takie zjawisko jest częste w przypadku podskal. O ile każda podskala mierzy pewne unikalne cechy, to często te podskale są ze sobą powiązane, bo odnoszą się do szerszego, wspólnego konstruktów (w tym przypadku ciemnej triady). Może to również wystąpić podczas walidacji dla konstrukcji zbieżnych. Na przykład, gdy oceniamy trafność konstruktów A, porównując go z innym podobnym konstruktów B, możemy oczekiwać pewnego stopnia korelacji między nimi, ponieważ oba są związane z podobnym obszarem funkcjonowania człowieka.

5 Walidacja

Z procesu badawczego wiemy, że jednym z kluczowych aspektów tworzenia narzędzi pomiarowych, takich jak testy i kwestionariusze, jest ich walidacja. Jak pamiętacie z naszych zajęć, istnieją trzy główne typy walidacji: trafność treściowa, trafność konstruktu i trafność kryterialna. Trafność treściowa jest zazwyczaj oceniana jakościowo, natomiast dwie pozostałe formy walidacji mają charakter ilościowy.

5.1 Trafność kryterialna

Założmy, że stworzyliśmy kwestionariusz oceniający narcyzm i chcemy ocenić jego trafność kryterialną. W kontekście teorii ciemnej triady zakładamy, że narcyzm i makiawelizm są ze sobą pozytywnie powiązane. Dlatego spodziewamy się, że istnieje pozytywna korelacja między tymi dwoma konstruktami. Aby to sprawdzić, użyjemy funkcji `cor.test()`:

```
cor.test(dane$makiawelizm, dane$narcyzm)
```

Z powyższej funkcji powinniśmy otrzymać istotną statystycznie i silną pozytywną korelację, co jest dowodem na to, że nasz kwestionariusz narcyzmu został prawidłowo zwalidowany w odniesieniu do makiawelizmu. Oczywiście, możemy również badać trafność kryterialną w odniesieniu do konstruktów rozbieżnych - tych, które teoretycznie powinny być ujemnie skorelowane z naszym kwestionariuszem. Przykładem takiego konstruktu może być np. empatia - zakładając, że osoby o wyższym poziomie narcyzmu mają niższą empatię.

W niektórych sytuacjach zamiast korzystać z korelacji, możemy wykorzystać test t. Na przykład, jeśli mamy teorię mówiącą, że dwie grupy (na przykład różne kraje lub kultury) powinny różnić się pod względem pewnej cechy, możemy użyć funkcji `t.test()`. Taki test pozwoli nam sprawdzić, czy istnieją statystycznie istotne różnice między grupami w zakresie mierzonej cechy.

```
t.test(makiawelizm ~ kraj, data=dane)
```

5.2 Eksploracyjna analiza czynnikowa

Innym kluczowym aspektem walidacji jest trafność konstruktu. Odnosi się ona do tego, czy nasz test rzeczywiście mierzy teoretyczny konstrukt, który miał mierzyć. Jednym z podejść do oceny trafności konstruktu jest eksploracyjna analiza czynnikowa (EFA). EFA pozwala na zbadanie, w jaki sposób różne elementy (w tym przypadku pozycje w kwestionariuszu) grupują się w większe kategorie, zwane czynnikami. EFA jest szczególnie przydatna, gdy chcemy zrozumieć strukturę naszego kwestionariusza i zweryfikować czy nasze itemy są

dobrymi indykatorami naszego konstruktów. Dla naszego kwestionariusza, teoretycznie zakładaliśmy, że powinien on zawierać dwie podskale: narcyzm i makiawelizm. Możemy to sprawdzić, korzystając z funkcji `fa()` z pakietu **psych**:

```
efa <- fa(dane[,1:18], nfactors = 2)
summary(efa)
print(efa$loadings, cutoff = 0.5)
```

Używając funkcji `print(efa$loadings, cutoff = 0.5)`, możemy również przyjrzeć się ładunkom czynnikowym dla poszczególnych pozycji. Ładunki te mówią nam o tym, jak mocno każda pozycja jest związana z określonym czynnikiem. Zakłada się, że itemy, których ładunek wynosi więcej niż 0.5 są akceptowalnymi indykatorami zmiennej psychologicznej.

Chociaż teoretycznie zakładamy obecność dwóch czynników, warto jest również przeprowadzić empiryczną weryfikację tej tezy. Jednym ze sposobów jest użycie wykresu osypiska (ang. scree plot). Wykres ten przedstawia wartości własne dla każdego czynnika i pozwala nam zobaczyć, ile czynników znacząco przyczynia się do wyjaśnienia wariancji w naszych danych:

```
scree(dane[,1:18])
```

W idealnej sytuacji, na wykresie zauważymy wyraźne "łamanie" linii, które wskazuje na optymalną liczbę czynników do uwzględnienia. Teoretycznie zakładając dwie podskale, spodziewalibyśmy się, że dwie wartości własne (oznaczone jako kropki na wykresie) będą znacząco wyższe niż pozostałe. Wspomnienie o wykresie osypiska i interpretacja wyników EFA dają nam pełniejszy obraz tego, jak nasz kwestionariusz mierzy teoretyczne konstrukty i pomaga w walidacji konstruktów.

5.3 Konfirmacyjna analiza czynnikowa

Po przeprowadzeniu Eksploracyjnej Analizy Czynnikowej (EFA) następnym krokiem jest często Konfirmacyjna Analiza Czynnikowa (CFA). Podczas gdy EFA służy do identyfikacji potencjalnych czynników w naszych danych, CFA pozwala na testowanie konkretnych, teoretycznych modeli czynnikowych. CFA pozwala na testowanie konkretnych hipotez dotyczących struktury czynnikowej. W przeciwieństwie do EFA, gdzie struktura jest "eksplorowana", w CFA mamy już jasno zdefiniowaną strukturę, którą chcemy potwierdzić. Dodatkowo CFA umożliwia ocenę jakości dopasowania określonego modelu do danych. Dzięki temu możemy dokładnie ocenić, czy nasz teoretyczny model jest spójny z rzeczywistością.

Podstawowym elementem CFA jest specyfikacja modelu. Model określa, jakie zmienne (lub pozycje) łączą się z którym czynnikiem (konstruktem psychologicznym):

```
model <- Makiawelizm =~ M1+M2+M3+M4+M5+M6+M7+M8+M9
Narcyzm =~ N1+N2+N3+N4+N5+N6+N7+N8+N9
```

Makiawelizm i Narcyzm to nazwy czynników, które chcemy przetestować. W tym przypadku mówimy, że mamy dwa czynniki. Symbol `=~` to specjalny operator w składni modelu, który oznacza "jest mierzony przez". Innymi słowy, mówimy, że czynnik "Makiawelizm" jest mierzony przez pozycje **M1, M2, ..., M9**, a czynnik "Narcyzm" jest mierzony przez pozycje **N1, N2, ..., N9**. M1, M2, ..., M9 i N1, N2, ..., N9 to nazwy konkretnych pozycji w naszym zestawie danych, które chcemy przypisać do odpowiednich czynników.

Po określeniu modelu czynnikowego, następnym krokiem jest faktyczne przeprowadzenie CFA. Wykorzystajmy kolejne fragmenty kodu, aby zrozumieć, co się dzieje.

```
cfa <- cfa(model, dane)
summary(cfa, fit.measures=TRUE)
```

W tej linii kodu wywołujemy funkcję **cfa**, która wykonuje confirmacyjną analizę czynnikową w oparciu o model, który wcześniej określiliśmy. Funkcja **summary** wykorzystywana z obiektem **cfa** dostarcza szczegółowe podsumowanie wyników analizy. Jest to podstawowe narzędzie do oceny, czy nasz model czynnikowy dobrze pasuje do danych. Argument **fit.measures=TRUE** instruuje R, aby wyświetlić różne miary dopasowania modelu (takie jak RMSEA, CFI, TLI itd.), które są kluczowe do oceny jakości dopasowania modelu.

Ostatnim elementem CFA jest możliwość wizualizacji otrzymanej struktury kwestionariusza. Poniższa linia kodu korzysta z funkcji **semPaths**, która jest częścią pakietu **semTools**. Pozwala ona na graficzne przedstawienie struktury czynnikowej naszego modelu.

```
semPaths(cfa, whatLabels="std", layout="tree")
```

Argument **whatLabels="std"** instruuje funkcję, aby wyświetlać załadunki czynnikowe w postaci standaryzowanej (tj. załadunki mające wartości od -1 do 1 - jak korelacje). Argument **layout="tree"** decyduje o układzie grafu, układając czynniki i zmienne w formie drzewa, co może ułatwić interpretację w przypadku bardziej złożonych modeli.

Podsumowując, dzięki tym liniom kodu możemy przeprowadzić confirmacyjną analizę czynnikową, ocenić, jak dobrze nasz teoretyczny model dopasowuje się do rzeczywistych danych oraz wizualnie przedstawić tę strukturę czynnikową. Wizualizacja jest szczególnie przydatna w psychologii, ponieważ może pomóc w lepszym zrozumieniu i interpretacji złożonych modeli czynnikowych.

5.4 Rzetelność: współczynnik Omega

Współczynnik Omega to alternatywa dla współczynnika alfa Cronbacha, przy czym wiele badań sugeruje, że omega jest bardziej adekwatnym wskaźnikiem

rzetelności, zwłaszcza gdy struktura czynnikowa testu jest bardziej złożona. Poniższa funkcja pozwala obliczyć rzetelność na podstawie analizy czynnikowej potwierdzającej (CFA):

```
omega <- semTools::reliability(cfa)
print(omega)
```

Funkcja ta dostarcza różnych wskaźników rzetelności, w tym alfa Cronbacha oraz różne wersje współczynnika omega. Ważne jest, by nie przejmować się zbyt wiele mnogością wskaźników – najistotniejszy jest podstawowy współczynnik **omega**.

Jeśli kwestionariusz, z którym pracujemy, składa się z dwóch podskal, takich jak w naszym przypadku Narcyzm i Makiawelizm, funkcja obliczy współczynniki rzetelności dla każdej z tych podskal oddzielnie. To pozwala ocenić, czy każda z podskal jest rzetelna i czy może być używana w dalszych analizach.